UdeA
Analytics &
DataScience

DATA STREAMING Y SERVICIOS EN LA NUBE

Procesamiento de Datos

UNIVERSIDAD
DE ANTIOQUIA
1 8 0 3

Magister - Efraín Alberto Oviedo
alberto.oviedo@udea.edu.co

UNIVERSIDAD DE ANTIOQUIA
FACULTAD DE INGENIERÍA
ESPECIALIZACIÓN EN ANALÍTICA Y CIENCIA DE DATOS

AGENDA

UdeA
Analytics &
DataScience

1. **Serialización de Datos**
   - Protocol Buffers
   - Apache Thrift
2. Procesamiento en Batch
3. Procesamiento en Streaming
4. Procesamiento en micro-batch

Serialización de Datos

- Proceso de codificación de un objeto en un flujo de bytes con el fin de almacenarlo o transmitirlo. El objeto recibido/leído, es considerado como idéntico al original

- También suele ser utilizado como método de persistencia de objetos en forma de archivos, en memoria o en base de datos

- Otro uso que se les da, permite detectar cambios en las variables en función del tiempo

Serialización de Datos

Proceso de Serialización

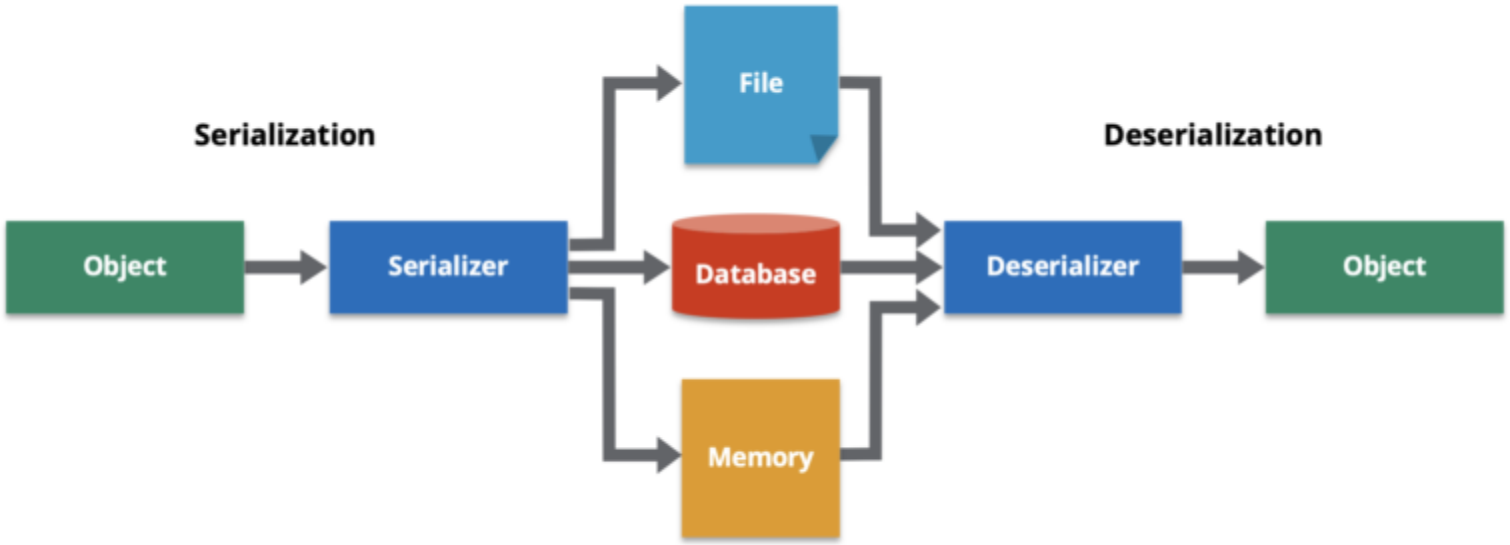

https://hazelcast.com/glossary/serialization/

Lenguajes de Serialización

https://community.cisco.com/t5/developer-general-knowledge-base/xml-vs-json-vs-yaml/ta-p/4729758

XML

XML (Lenguaje extensible de marcas)

- Estándar internacionalmente conocido

- Define etiquetas personalizadas para describir y organizar datos

- Se utiliza para transferir información de productos, transacciones, inventario, etc.

XML

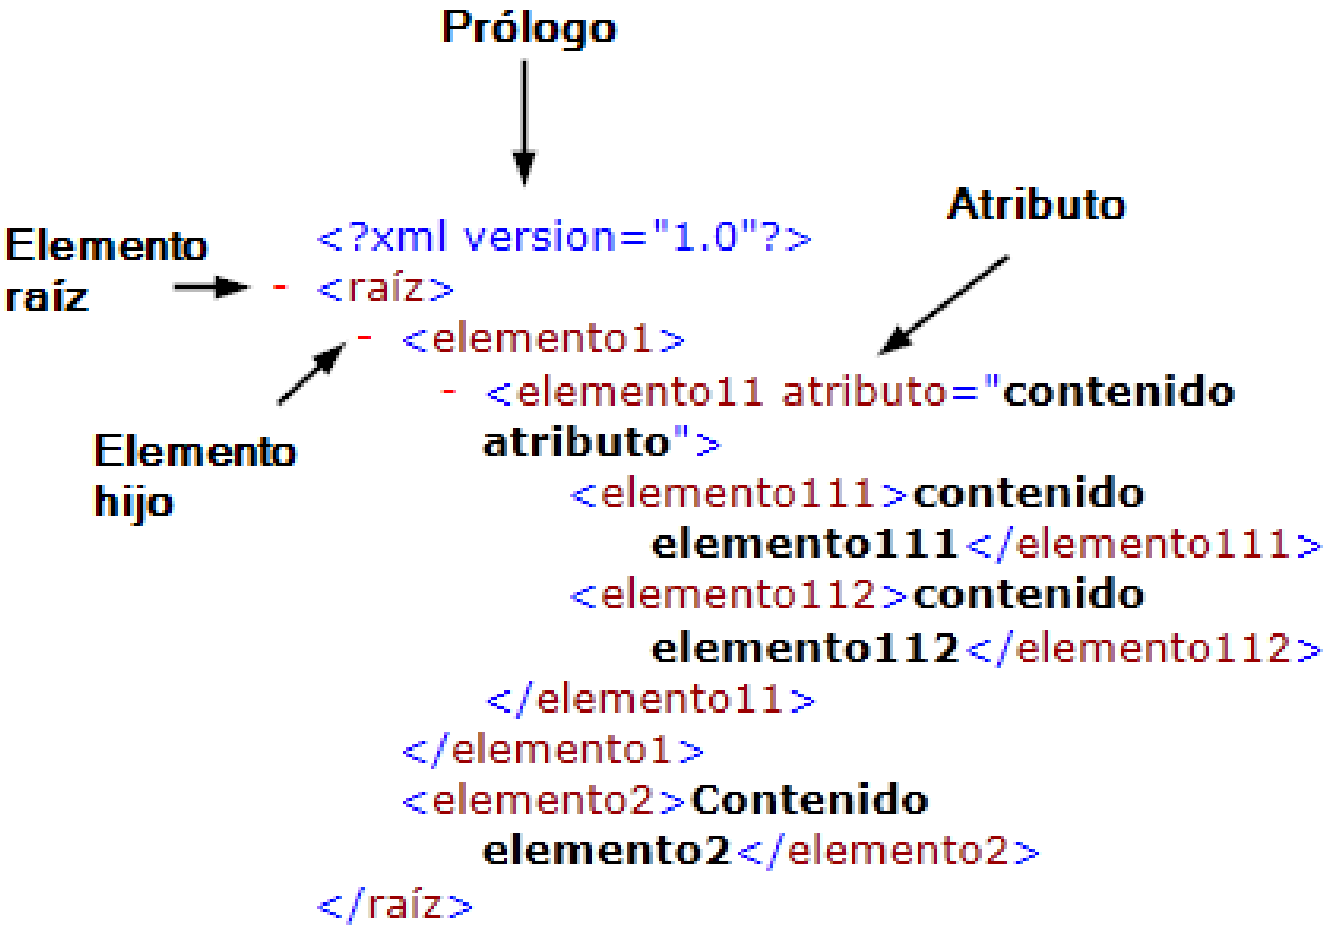

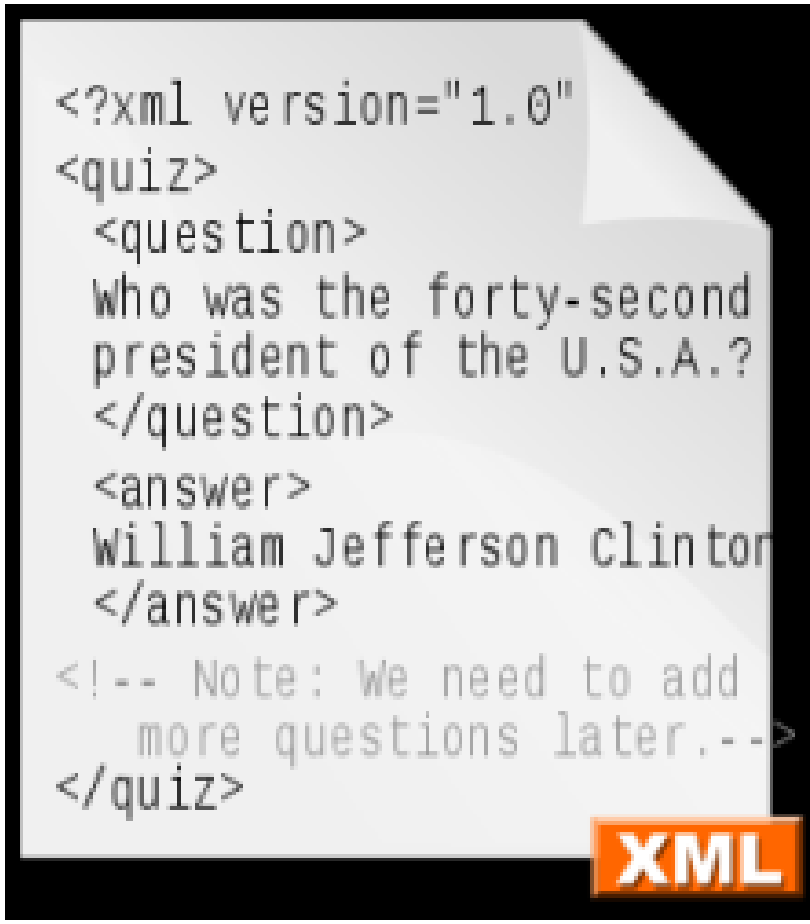

https://www.filmac.com/xml-el-lenguaje-sin-vocabulario-de-uso-universal/

XML

ID	Nombre	Edad	Sexo	Profesión	Salario
1	Juan	33	M	Ingeniero	4.500.000
2	Ana	38	F	Arquitecta	6.200.000

```
<?xml version="1.0" encoding="UTF-8" ?>
<empleados>
        <Id>1</Id>
        <Nombre>Juan</Nombre>
        <Edad>33</Edad>
        <Sexo>M</Sexo>
        <Profesión>Ingeniero</Profesión>
        <Salario>4500000</Salario>
</empleados>
<empleados>
        <Id>2</Id>
        <Nombre>Ana</Nombre>
        <Edad>38</Edad>
        <Sexo>F</Sexo>
        <Profesión>Arquitecta</Profesión>
        <Salario>6200000</Salario>
</empleados>
```

JSON

JSON (JavaScript Object Notation)

- Representa datos estructurados en la sintaxis de JavaScript

- Permite transmitir datos en aplicaciones Web

- Es un archivo de texto con extensión .json

JSON

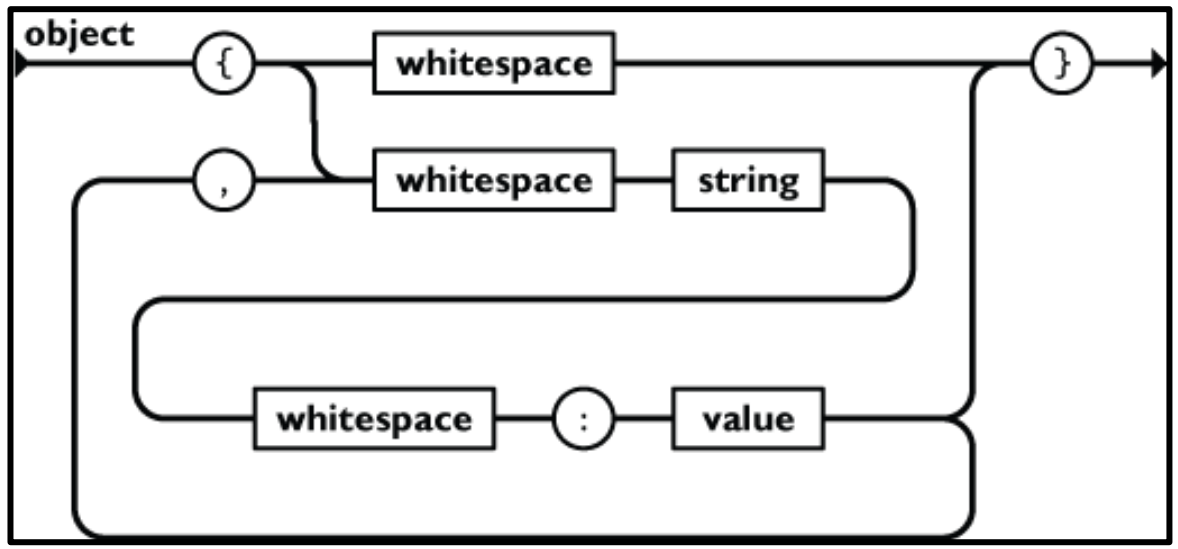

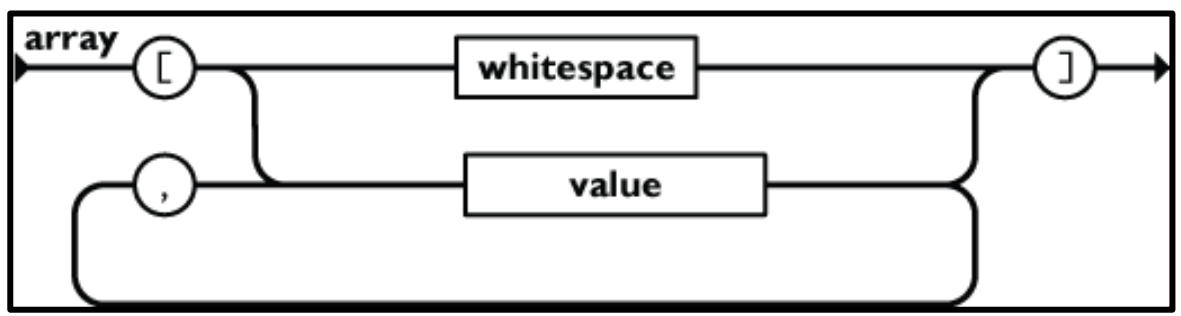

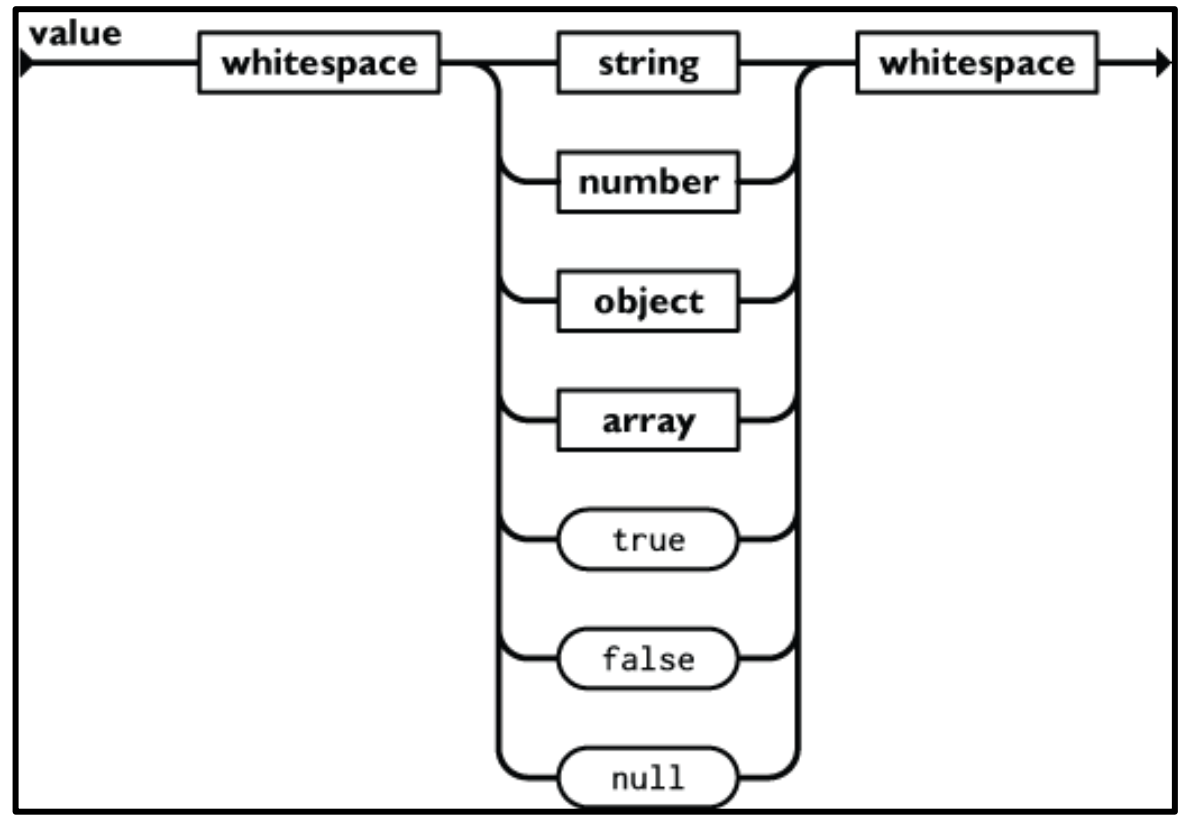

https://www.json.org/

JSON

ID	Nombre	Edad	Sexo	Profesión	Salario
1	Juan	33	M	Ingeniero	4.500.000
2	Ana	38	F	Arquitecta	6.200.000


```
{
  "empleados": [
    {
      "Id": 1,
      "Nombre": "Juan",
      "Edad": 33,
      "Sexo": "M",
      "Profesión": "Ingeniero",
      "Salario": 4500000
    },
    {
      "Id": 2,
      "Nombre": "Ana",
      "Edad": 38,
      "Sexo": "F",
      "Profesión": "Arquitecta",
      "Salario": 6200000
    }
  ]
}
```

YAML

YAML (YAML Ain't Markup Language)

- Lenguaje de serialización de datos utilizado frecuentemente en el diseño de archivos de configuración.

- Fue diseñado para ser útil y amigable para las personas que trabajan con datos

- La sangría se usa para la estructura, los dos puntos separan los pares clave valor y los guiones crean listas con viñetas

- Los archivos generados tienen extensión .yml o .yaml

```
YAML: YAML Ain't Markup Language™

What It Is:
  YAML is a human-friendly data serialization
  language for all programming languages.

YAML Resources:
  YAML Specifications:
  - YAML 1.2:
    - Revision 1.2.2       # Oct 1, 2021 *New*
    - Revision 1.2.1       # Oct 1, 2009
    - Revision 1.2.0       # Jul 21, 2009
  - YAML 1.1
  - YAML 1.0

  YAML Matrix Chat:  '#chat:yaml.io'     # Our New Group Chat Room!
  YAML IRC Channel:  libera.chat#yaml    # The old chat
  YAML News:         twitter.com/yamlnews
  YAML Mailing List: yaml-core           # Obsolete, but historical

  YAML on GitHub:                        # github.com/yaml/
    YAML Specs:         yaml-spec/
    YAML 1.2 Grammar:   yaml-grammar/
    YAML Test Suite:    yaml-test-suite/
    YAML Issues:        issues/

  YAML Reference Parsers:
  - Generated Reference Parsers
  - YPaste Interactive Parser
```

YAML

https://yaml.org/

YAML

ID	Nombre	Edad	Sexo	Profesión	Salario
1	Juan	33	M	Ingeniero	4.500.000
2	Ana	38	F	Arquitecta	6.200.000

```yaml
empleados:
  - Id: 1
    Nombre: Juan
    Edad: 33
    Sexo: M
    Profesion: Ingeniero
    Salario: 4500000
  - Id: 2
    Nombre: Ana
    Edad: 38
    Sexo: F
    Profesion: Arquitecta
    Salario: 6200000
```

Ejercicio

Represente en formato XML, JSON y YAML la información relacionada con las ciudades que ha visitado (País, departamento, fecha de visita, duración, motivo, etc)

Valide el ejercicio con un editor online

- https://jsoneditoronline.org/
- https://jsonformatter.org/
- https://jsonformatter.org/yaml-formatter

AGENDA

UdeA
Analytics &
DataScience

1. **Serialización de Datos**
   - **Protocol Buffers**
   - Apache Thrift
2. Procesamiento en Batch
3. Procesamiento en Streaming
4. Procesamiento en micro-batch

Protocol Buffers

Formato de serialización de datos que facilita el intercambio de datos entre aplicaciones, aún si están desarrolladas en distintos lenguajes.

Desarrollado por Google y liberado en 2008 como proyecto de código abierto. Pensado par reemplazar el formato xml con el objetivo de ser mas simple y rápido

La comunicación se realiza en formato cliente – servidor de forma local o remota, utilizando

Asigna etiquetas a los datos para utilizar un formato binario

Protobuf - Proceso

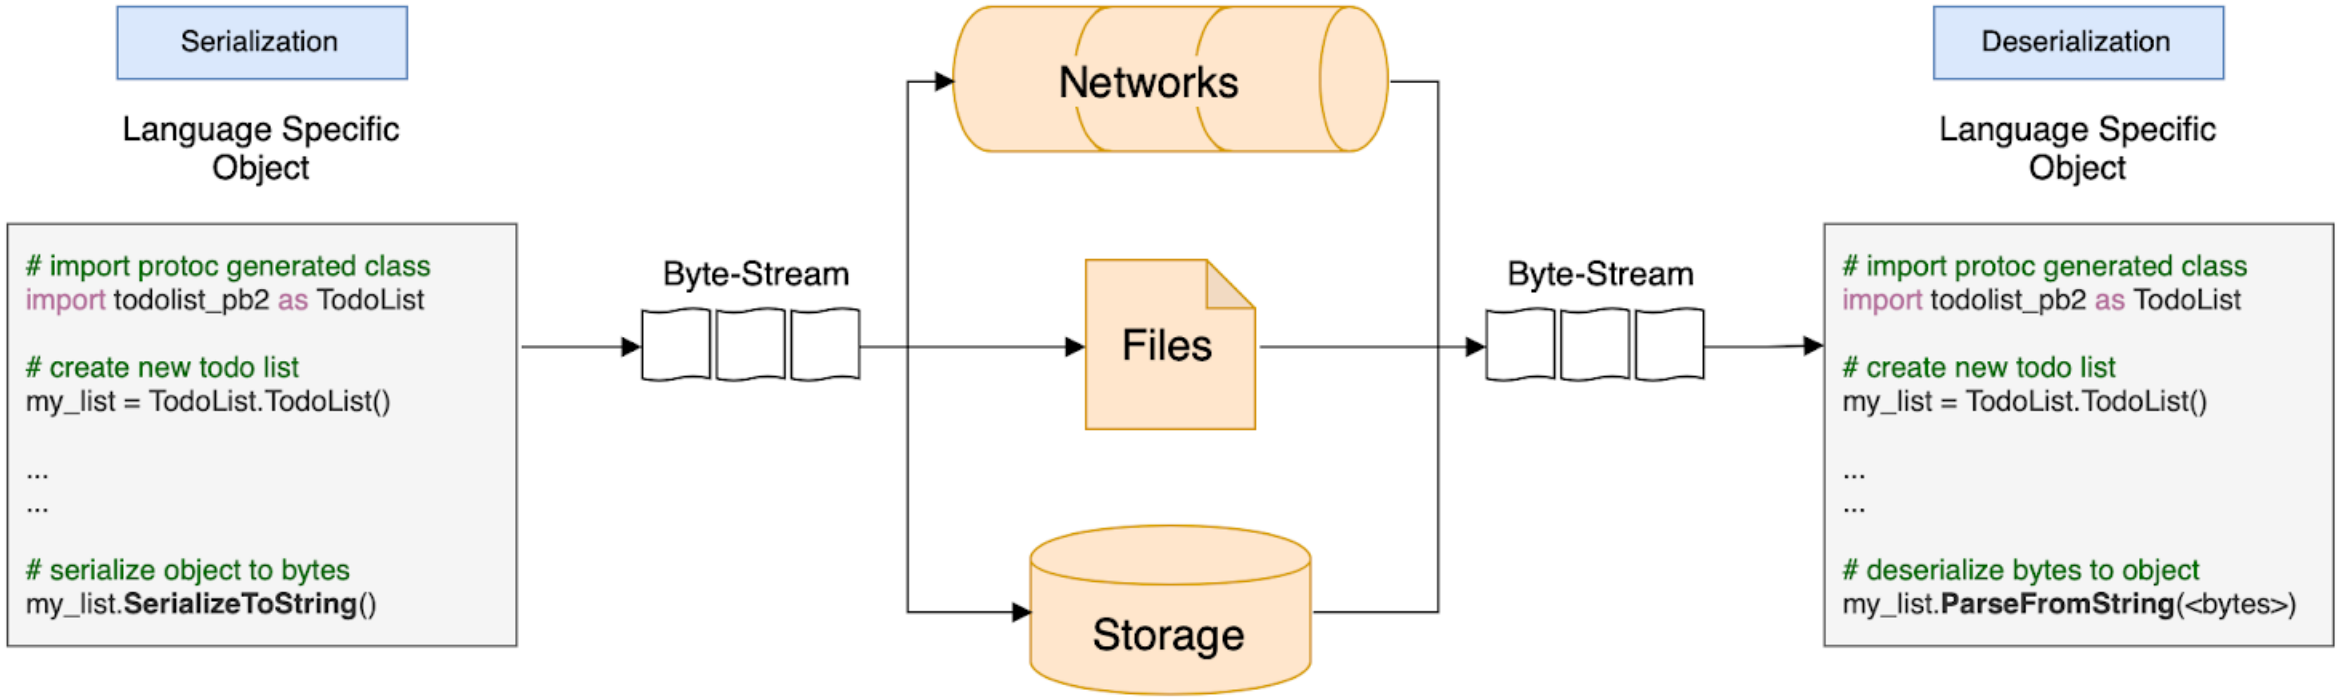

https://www.freecodecamp.org/news/googles-protocol-buffers-in-python/

Protobuf - Rendimiento

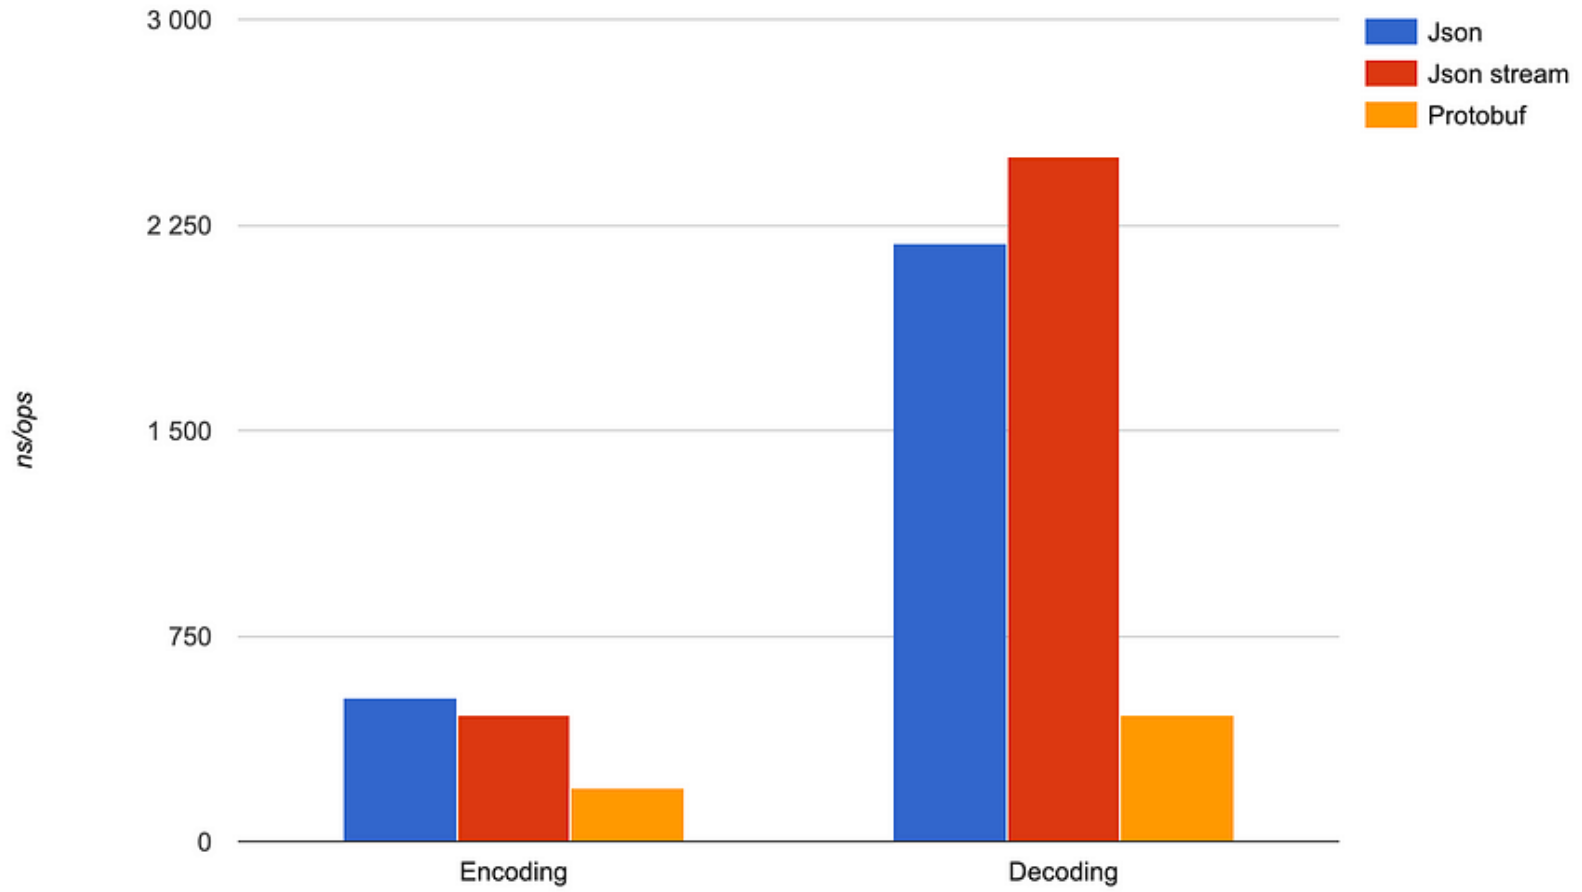

https://mnwa.medium.com/what-the-hell-is-protobuf-4aff084c5db4

Protobuf – Empleados

empleado.proto

```
syntax = "proto3";
message Empleado {
int32 id = 1;
string nombre = 2;
int32 edad = 3;
string sexo = 4;
string profesion = 5;
int32 salario = 6;
}
```

```
emp1.id = 1
emp1.nombre = 'Juan'
emp1.edad = 33
emp1.sexo = 'M'
emp1.profesion = 'Ingeniero'
emp1.salario = 4500000
```

```
b'\x08\x01\x12\x04Juan\x18!"\x01M*\tIngeniero0\xa0\xd4\x92\x02'
```

```
syntax = "proto2";

package tutorial;

message Person {
  optional string name = 1;
  optional int32 id = 2;
  optional string email = 3;

  enum PhoneType {
    MOBILE = 0;
    HOME = 1;
    WORK = 2;
  }

  message PhoneNumber {
    optional string number = 1;
    optional PhoneType type = 2 [default = HOME];
  }

  repeated PhoneNumber phones = 4;
}

message AddressBook {
  repeated Person people = 1;
}
```

Protobuf

Tutorial
https://protobuf.dev/getting-started/pythontutorial/

Guía de programación
https://protobuf.dev/programming-guides/proto3/

AGENDA

UdeA
Analytics &
DataScience

1. **Serialización de Datos**
   - Protocol Buffers
   - **Apache Thrift**
2. Procesamiento en Batch
3. Procesamiento en Streaming
4. Procesamiento en micro-batch

Apache Thrift

Protocolo para la gestión de los macrodatos, que a demás de permitir serialización de objetos en formato binario, incluye el desarrollo de interfaces de servicios utilizando archivos de extensión .thrift

Se enfoca principalmente en la capa de comunicación entre el cliente y el servidor RPC (Llamado a procedimientos remotos)

Fue desarrollado por Facebook y posteriormente liberado, es de código abierto y se utiliza generalmente en C++ pero se puede adaptar a otros lenguajes

Utiliza un lenguaje de descripción de interfaz (IDL) para definir la estructura de los datos y las interfaces de los servicios

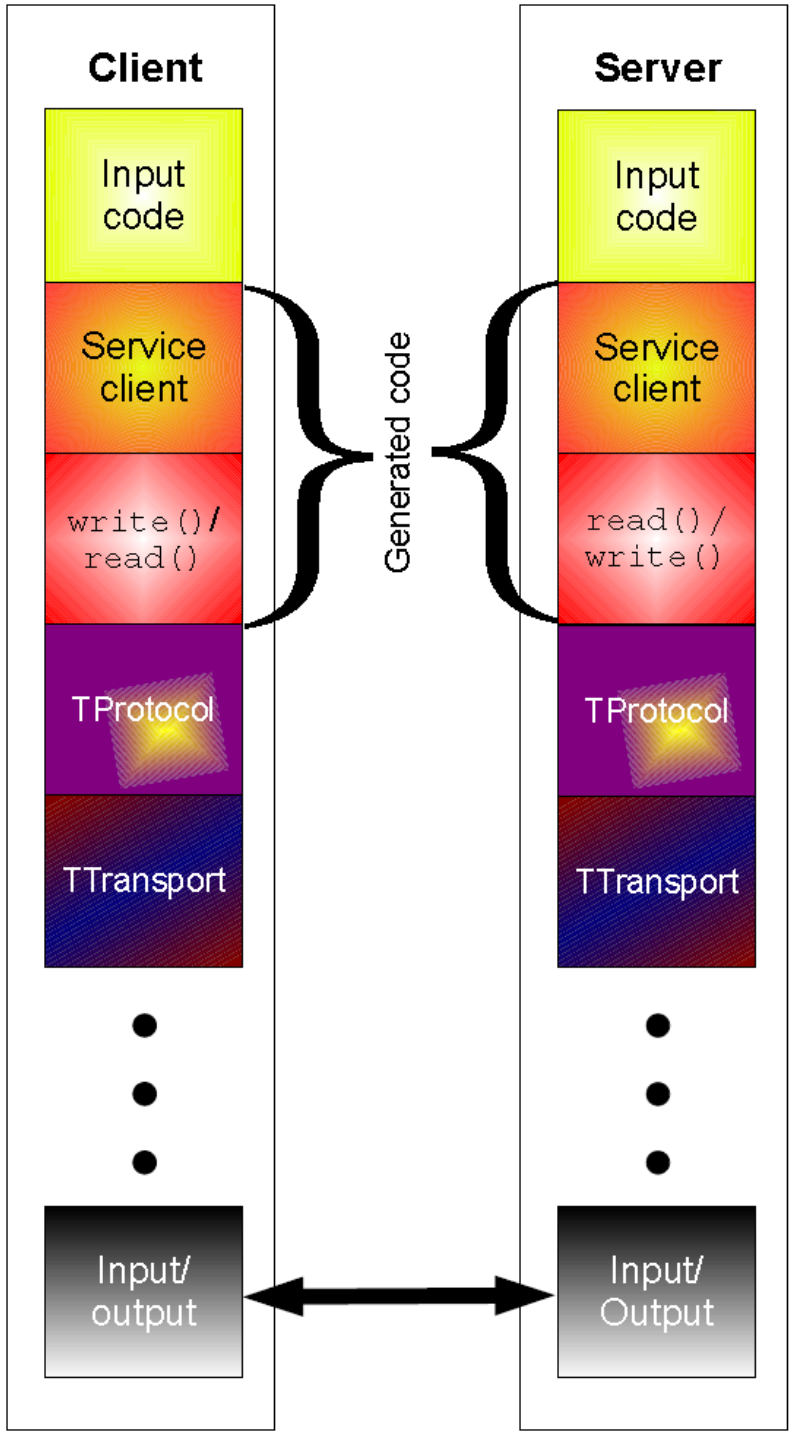

Apache Thrift

A partir del archivo .thrift se genera código tanto para el cliente como para el servidor que permite el intercambio de datos.

Protocolos (Binario, Json, etc)

Transporte (Socket, Memoria, etc)

Apache Thrift

empleado.thrift

```
struct Empleado {
  1: i32 id,
  2: string nombre,
  3: i32 edad,
  4: string sexo,
  5: string profesion,
  6: i32 salario,
}

service EmpleadoServicio {
  string msg(),
  string send_Emp(1: Empleado
new_emp),
  bool mayor40(1: Empleado emp)
}
```

!thrift -r --gen py local/data/empleado.thrift

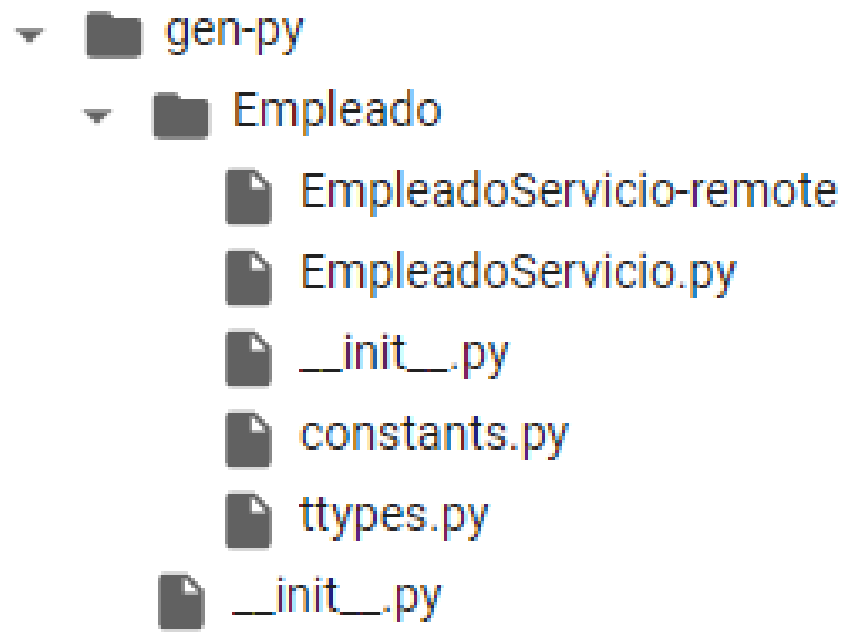

https://dataschool.com/data-modeling-101/running-jupyter-notebook-on-an-ec2-server/

AGENDA

UdeA
Analytics &
DataScience

1. Serialización de Datos
   - Protocol Buffers
   - Apache Thrift
2. **Procesamiento en Batch**
3. Procesamiento en Streaming
4. Procesamiento en micro-batch

Procesamiento en Batch

- El procesamiento en Batch o por lotes, contempla la carga y proceso de grandes volúmenes de datos para realizar tareas repetitivas de manera automática.
- Requieren una interacción humana mínima ejecutando de manera eficiente tareas repetitivas
- Se recomienda utilizarlos en proceso que tomen mucho tiempo en ser realizado sea por el gran volumen de los datos o por la complejidad misma del proceso

https://reysantech.com/blog/como-se-procesa-la-informacion-en-big-data/

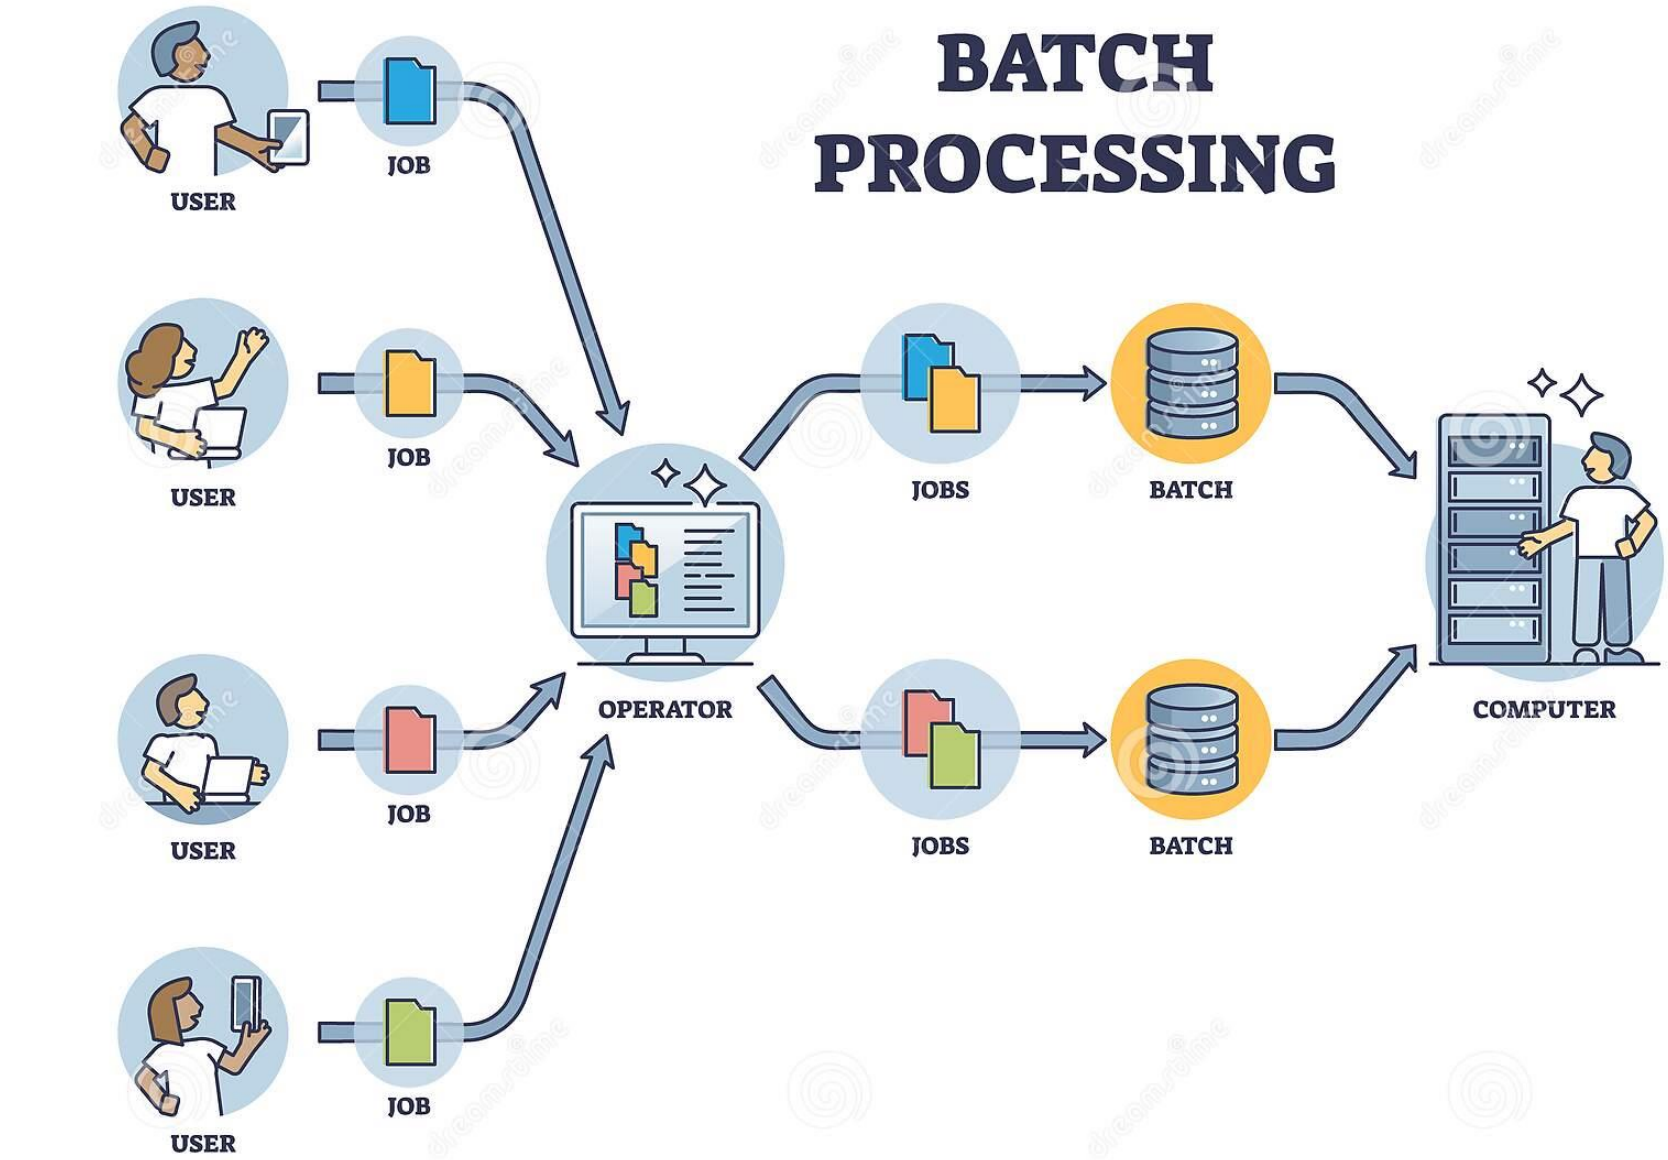

Procesamiento en Batch

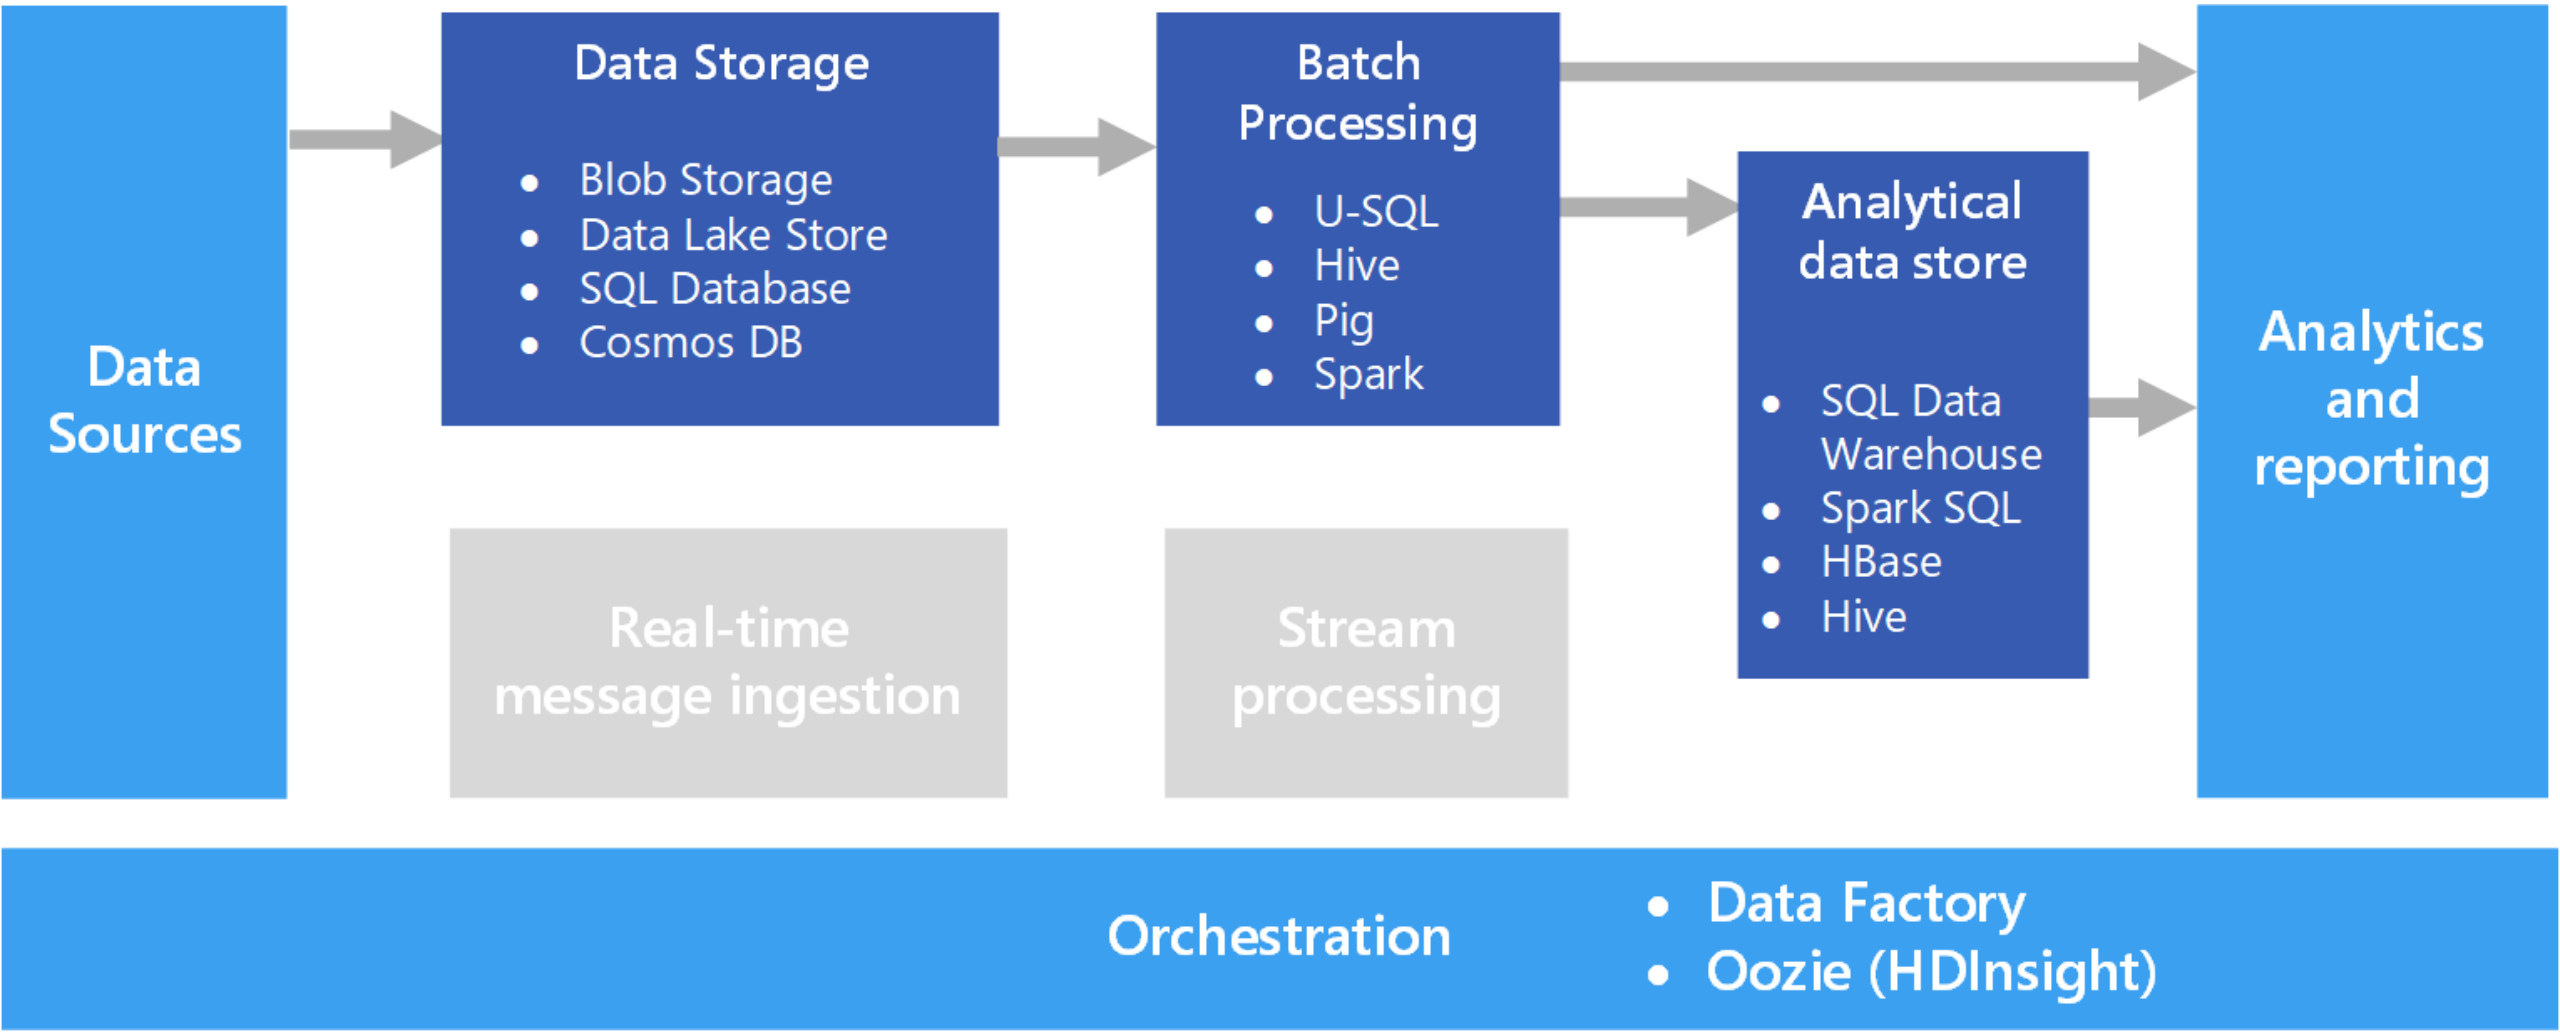

https://learn.microsoft.com/es-es/azure/architecture/data-guide/big-data/batch-processing

Data Lake

Data Lake (Lago de datos) consiste en un repositorio centralizado donde es posible almacenar grandes cantidades de datos estructurados y no estructurados

Permite almacenar los datos tal y como están y procesarlos posteriormente bajo demanda, es decir que no es necesario almacenarlos con una estructura de datos definida

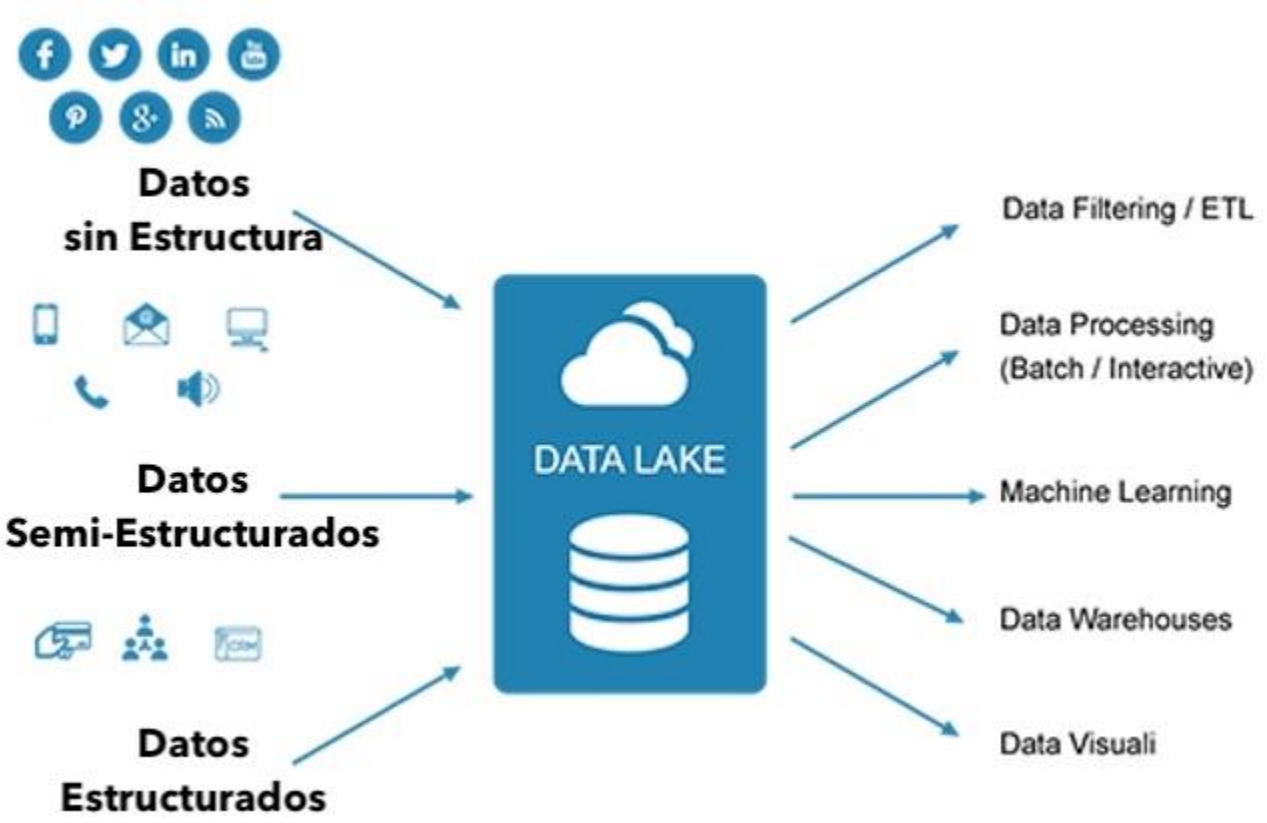

Data Lake

Características	Almacenamiento de datos	Lago de datos
Datos	Relacionales provenientes de sistemas transaccionales, bases de datos operativas y aplicaciones de línea de negocio	No relacionales y relacionales provenientes de dispositivos de IoT, sitios web, aplicaciones móviles, redes sociales y aplicaciones corporativas
Esquema	Diseñado con anterioridad a la implementación del almacenamiento de datos (esquema en escritura)	Escrito al momento del análisis (esquema en lectura)
Precio/desempeño	Resultados de búsqueda más rápidos con almacenamiento de mayor costo	Resultados de consultas que se tornan más rápidos con almacenamiento de bajo costo
Calidad de los datos	Datos seleccionados cuidadosamente que funcionan como la versión central de la verdad	Cualquier dato seleccionado o no (es decir, datos sin procesar)
Usuarios	Analistas de negocios	Científicos de datos, desarrolladores de datos y analistas de negocios (con datos seleccionados)
Análisis	Generación de informes en lotes, inteligencia empresarial y visualizaciones	*Machine learning*, análisis predictivo, detección de datos y creación de perfiles

https://aws.amazon.com/es/big-data/datalakes-and-analytics/what-is-a-data-lake/

AGENDA

UdeA
Analytics &
DataScience

1. Serialización de Datos
   - Protocol Buffers
   - Apache Thrift
2. Procesamiento en Batch
3. **Procesamiento en Streaming**
4. Procesamiento en micro-batch

Procesamiento en Streaming

- El procesamiento en streaming o flujo de datos permite procesar los datos de forma continua en el mismo instante en que llegan sin esperar ningún otro evento
- Cada lectura de datos se concibe como un flujo de datos que pueden representarse como un conjunto de lista de valores o como un conjunto de pares clave-valor

https://reysantech.com/blog/como-se-procesa-la-informacion-en-big-data/

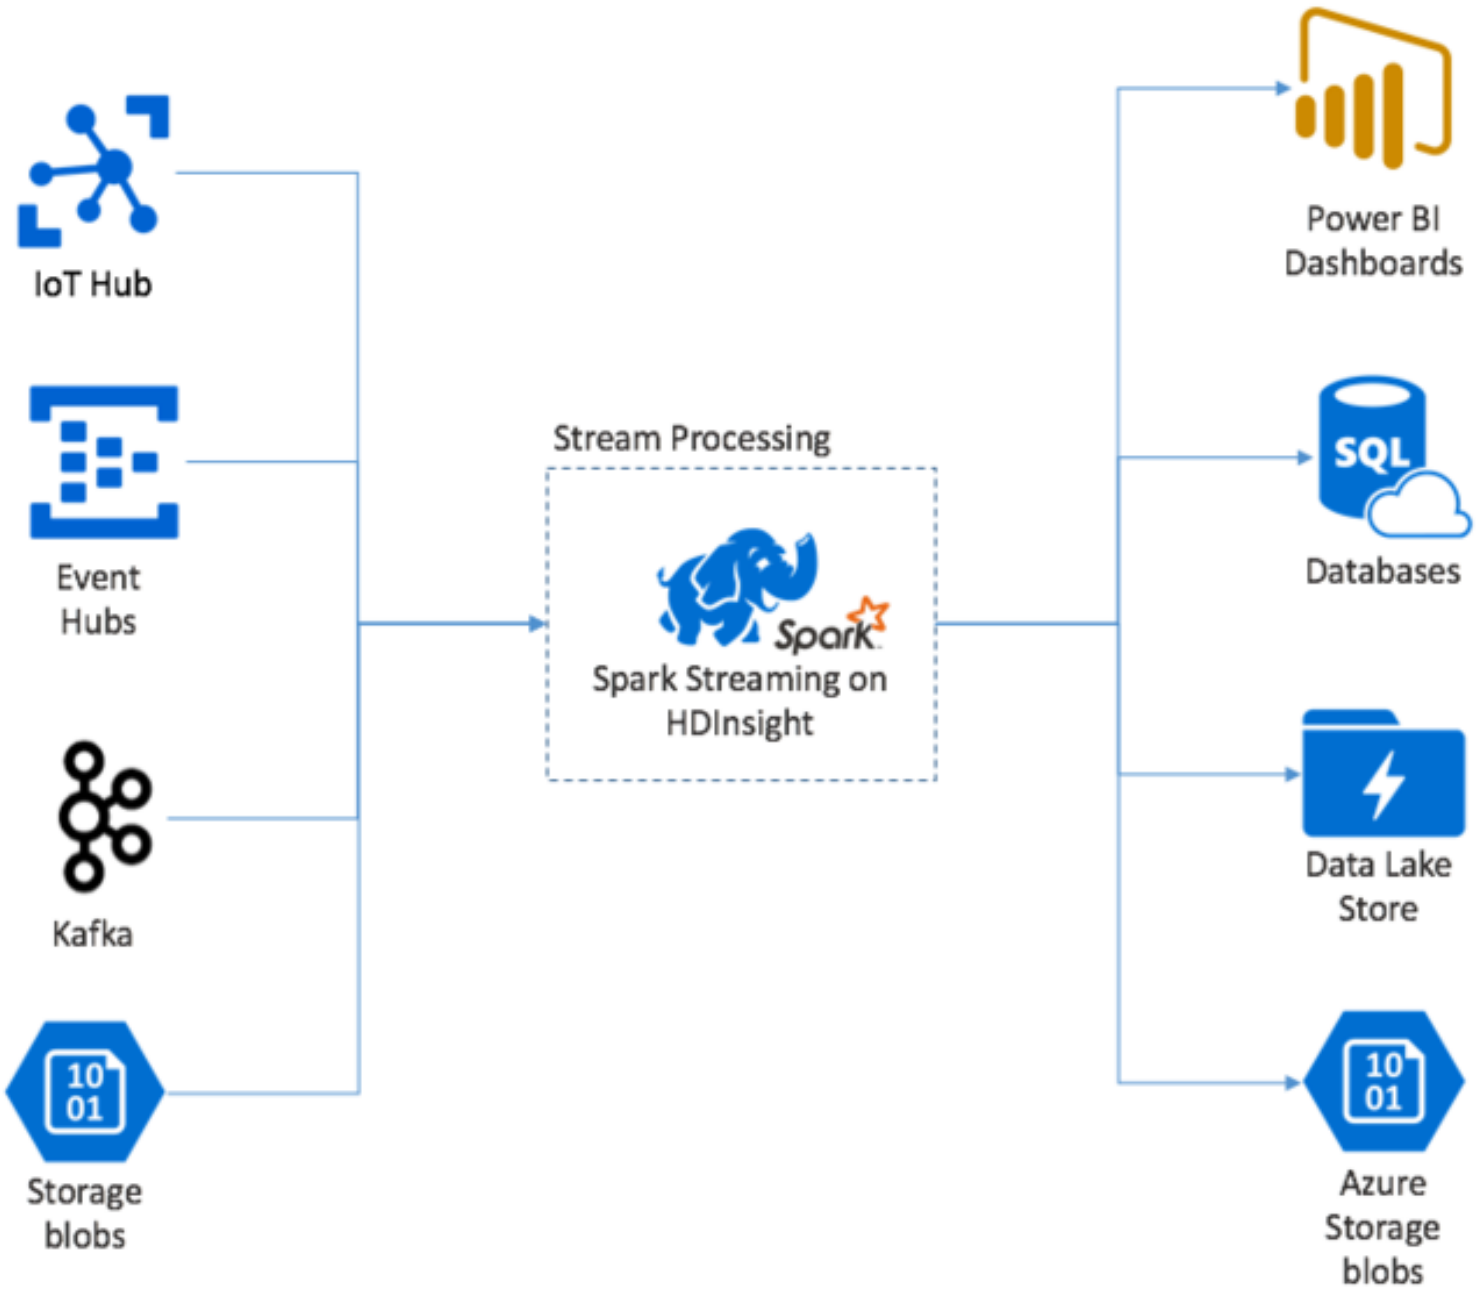

El procesamiento de datos en Streaming usualmente es realizado en cluster de Spark que garantizan que cada uno de los eventos sea procesado de manera correcta incluyendo el concepto de la tolerancia a fallas

https://learn.microsoft.com/es-es/azure/hdinsight/spark/apache-spark-streaming-overview

Data Stream

- Data Stream o flujo de datos se refiere a la transmisión de una secuencia de señales codificada digitalmente en paquetes para transmitir información

- Data Stream tiene la necesidad de procesar y realizar análisis en tiempo real

- En el Data Stream cuenta con una naturaleza continua de generación de datos a gran velocidad, que implica que los datos sean procesados sin necesidad de ser previamente almacenados

AGENDA

UdeA
Analytics &
DataScience

1. Serialización de Datos
   - Protocol Buffers
   - Apache Thrift
2. Procesamiento en Batch
3. Procesamiento en Streaming
4. **Procesamiento en micro-batch**

Procesamiento en micro-batch

- El procesamiento en micro lotes consiste en agrupar los datos en pequeños grupos o lotes para luego ser procesados en conjunto.

- Es una variante del procesamiento por lotes, donde se procesan grupos pequeños de nuevos datos y se debe determinar una frecuencia de procesamiento de datos.

- A pesar de no ser un verdadero procesamiento en tiempo real, es suficiente para un gran número de aplicaciones

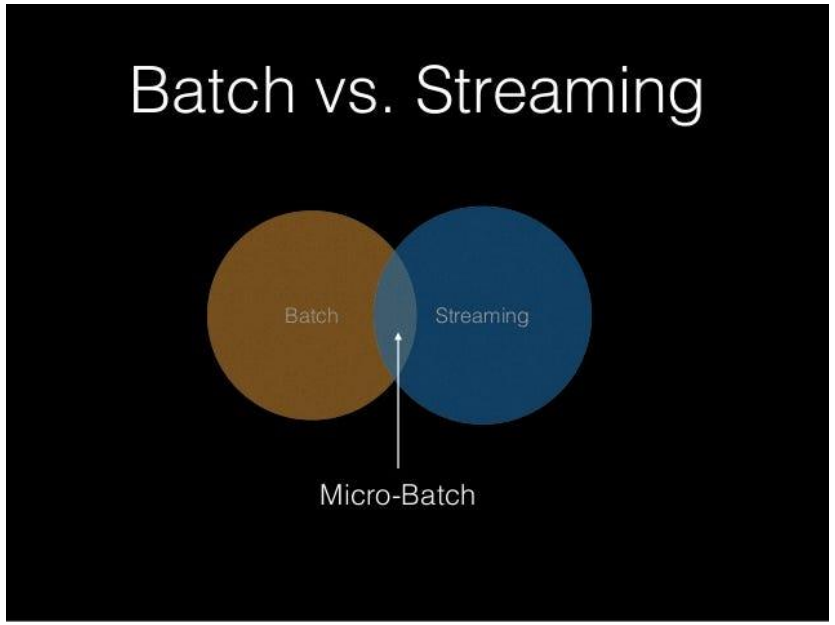

Procesamiento en micro-batch

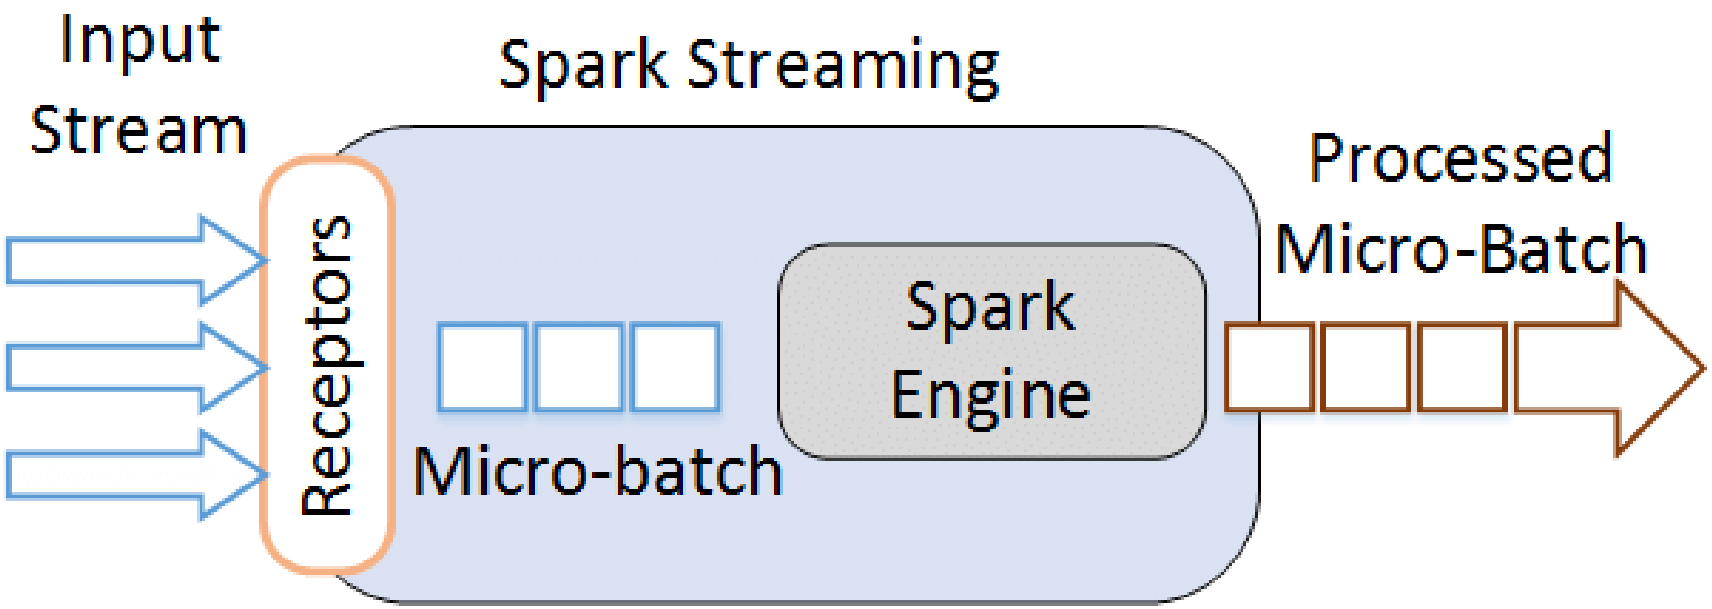

https://www.researchgate.net/figure/Micro-batch-processing-used-in-Spark-stream-The-input-streams-are-received-by_fig6_327183263

micro-batch vs Native Stream

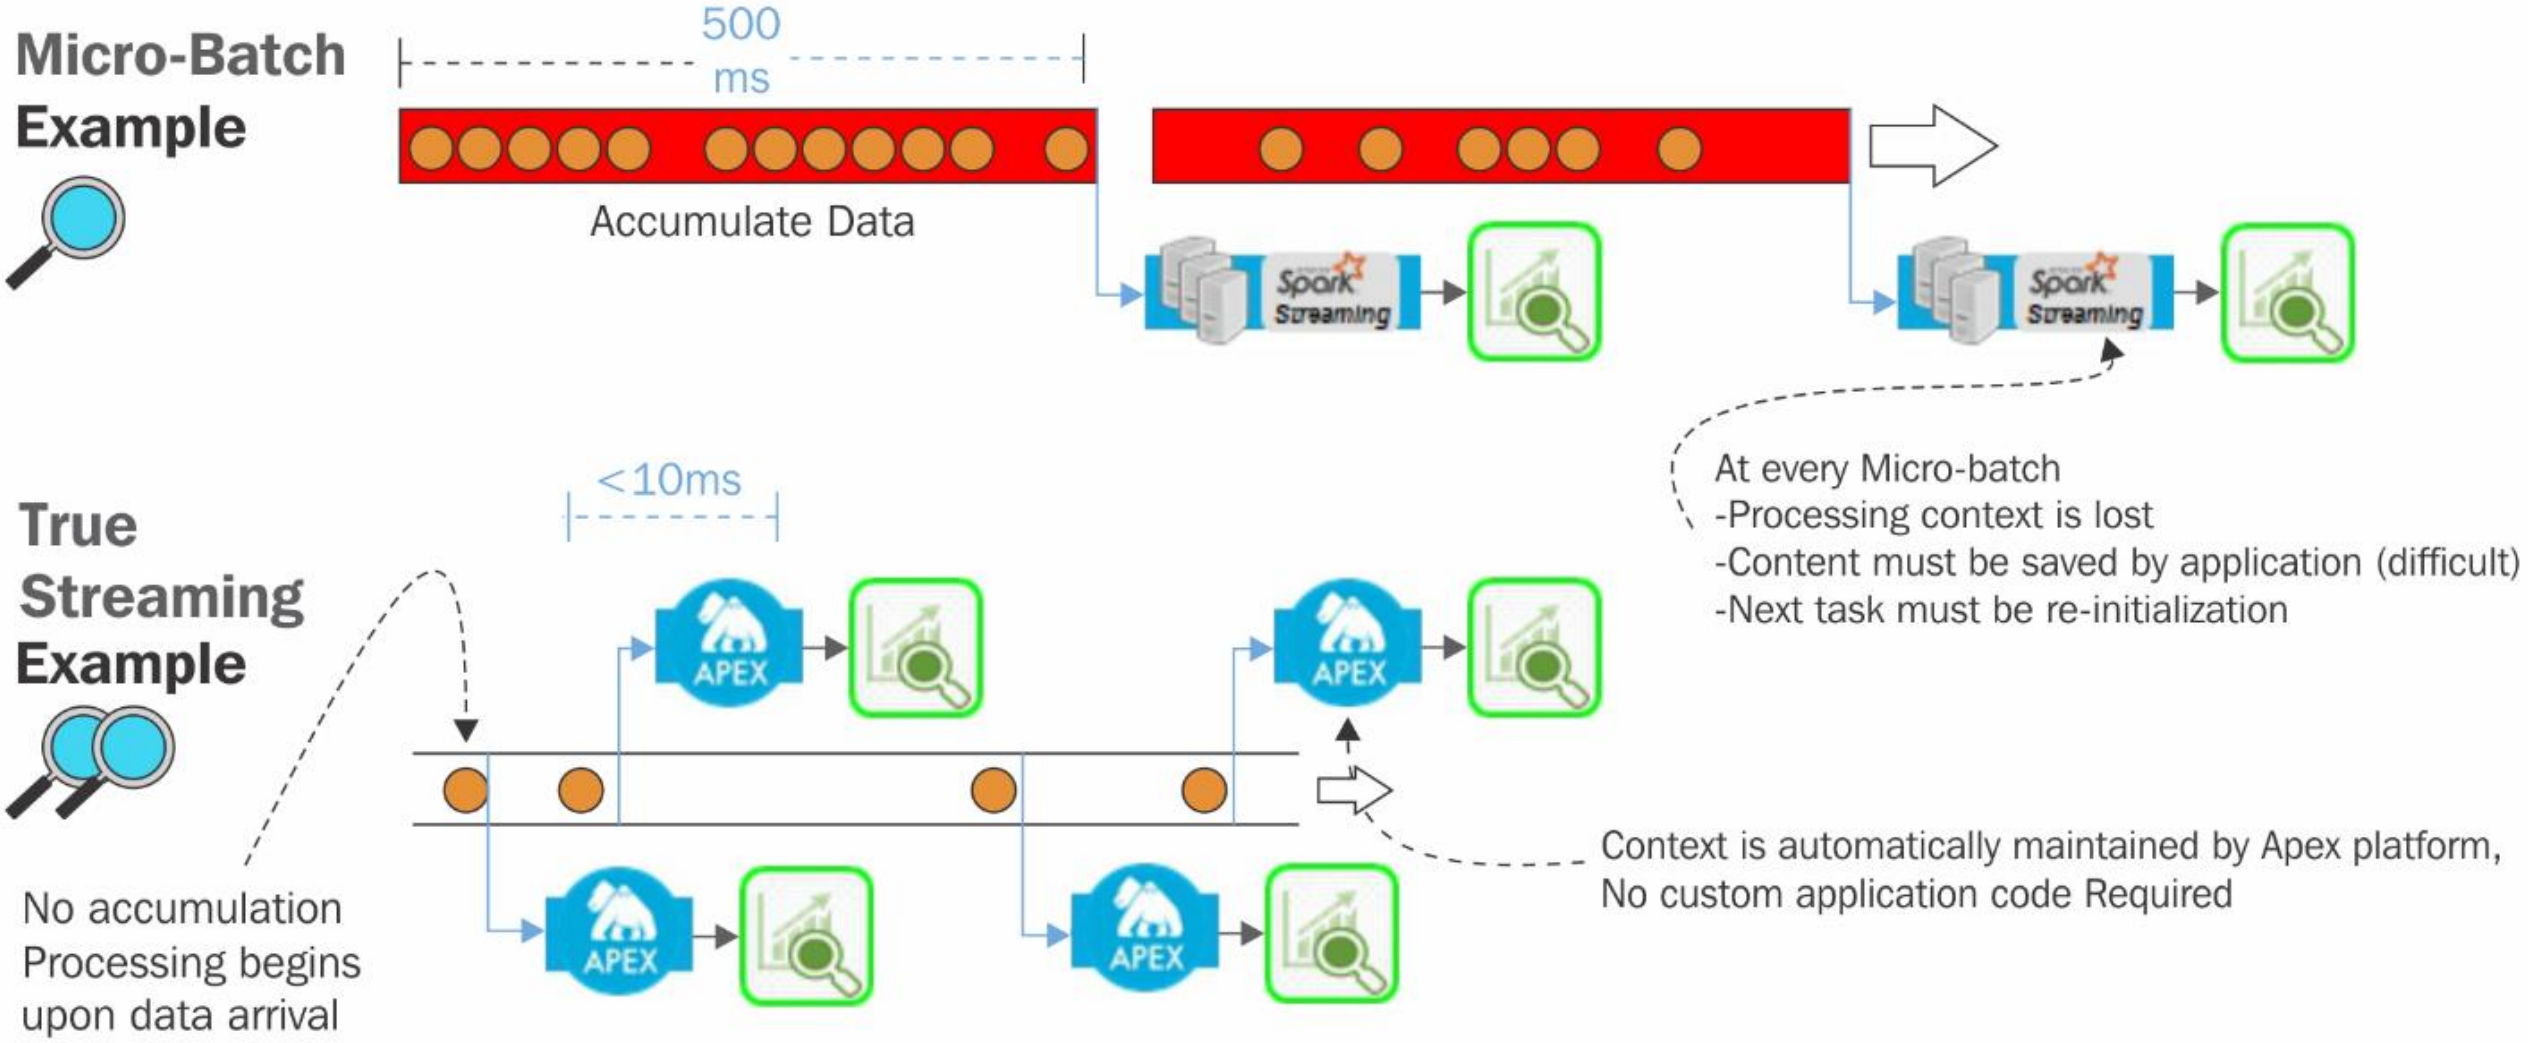

https://www.oreilly.com/library/view/learning-apache-apex/9781788296403/03a5ebbf-2a16-4a24-ab20-10175358ab7b.xhtml